

# TRAVAUX PRATIQUES N°1

## Initiation à Python

### Méthode des moindres carrés

Objectif : blabla

## 1 Introduction à Python

```
1 //comment
2 function c=fct1(n)
3 if (n<0) | (int(n)<>n) then
4     c=0;
5 else
6     c=1;
7     for i=1:n
8         c=c*i;
9     end
10 end
11 endfunction
12
13 a=5+6
14 sqrt(12)
15 ans -1
16 (1+%i)^3
17 a=[1,2,3], b=[1 2 3]
18 cos(a)
```

transposée  
inverse d'une matrice  
Affichage graphique d'une courbe  
Chargement & manipulation images

## 2 Ajout d'un bruit blanc gaussien additif

1D et 2D.

## 3 Méthode des moindres carrés

La méthode des moindres carrés est utilisée lorsque l'on souhaite ajuster une fonction sur un ensemble de données. Plus précisément, on considère une famille de fonctions  $\mathcal{F}$  dont les éléments  $f_a$  dépendent d'un paramètre  $a \in \mathbb{R}^d$ . Un exemple très simple est celui des fonctions linéaires, paramétrées par un paramètre réel  $a \in \mathbb{R}$  :

$$\mathcal{F} = \left\{ f_a : \mathbb{R} \rightarrow \mathbb{R}, x \mapsto ax \mid a \in \mathbb{R} \right\}$$

On dispose d'un ensemble de données, dont on suppose qu'il est généré par une fonction de la famille  $\mathcal{F}$ , c'est-à-dire qu'on dispose d'un ensemble de points  $\{(x_i, y_i)\}_{1 \leq i \leq n}$  tel que

$$\forall i \in \llbracket 1; n \rrbracket, \quad y_i \approx f_{a_0}(x_i)$$

où  $x_i \in \mathbb{R}^p$  et  $y_i \in \mathbb{R}^q$  pour tout  $i \in \llbracket 1; n \rrbracket$ . L'absence de l'égalité exacte peut être due à l'existence d'un bruit d'acquisition (arrondi numérique, erreur ou imprécision) ou simplement à l'approximation de la modélisation. Dans de nombreuses applications, on cherche à trouver la *meilleure* fonction de  $\mathcal{F}$  qui modélise la génération des données. Autrement dit, étant donné l'ensemble des données  $u = \{(x_i, y_i)\}_{1 \leq i \leq n}$ , quelle est la fonction  $f_a \in \mathcal{F}$  pour laquelle le nuage de points  $v_{f_a} = \{(x_i, f_a(x_i))\}_{1 \leq i \leq n}$  se rapproche le plus des données initiales  $u$ ? Ces deux ensembles de points appartenant à un espace euclidien, on peut<sup>1</sup> mesurer la distance entre ces deux ensembles à l'aide d'une distance de FROBENIUS :

$$\|v_{f_a} - u\|_F^2 = \sum_{i=1}^n \|x_i - x_i\|_2^2 + \|f_a(x_i) - y_i\|_2^2 = \sum_{i=1}^n \|f_a(x_i) - y_i\|_2^2$$

Le problème d'ajustement peut donc s'écrire comme le problème d'optimisation suivant :

$$\min_{f_a \in \mathcal{F}} \sum_{i=1}^n \|f_a(x_i) - y_i\|_2^2$$

ce qui revient à minimiser l'erreur au carré moyenne entre les données  $y_i$  et le modèle théorique  $f_a(x_i)$ ; d'où le nom de méthode des *moindres carrés*. Puisque la famille  $\mathcal{F}$  est paramétrée par le vecteur  $a \in \mathbb{R}^d$ , la forme finale du problème d'ajustement devient

$$\min_{a \in \mathbb{R}^d} \sum_{i=1}^n \|f_a(x_i) - y_i\|_2^2$$

On se place à présent dans le cas où  $\mathcal{F}$  est l'ensemble des formes linéaires :

$$\mathcal{F} = \left\{ f_a : \mathbb{R}^p \rightarrow \mathbb{R}, x \mapsto \langle a, x \rangle \mid a \in \mathbb{R}^p \right\}$$

On dispose d'un ensemble de données  $u = (X, y) \in \mathcal{M}_{n,p}(\mathbb{R}) \times \mathbb{R}^n$  avec  $X = (x_i)_{1 \leq i \leq n}$  et  $y = (y_i)_{1 \leq i \leq n}$ . On suppose que  $n > p$ . On cherche à résoudre le problème

$$\min_{a \in \mathbb{R}^p} J(a) = \sum_{i=1}^n (\langle a, x_i \rangle - y_i)^2 = \|Xa - y\|_2^2 \quad (\mathcal{P}_{\text{mm}})$$

### Exercice 1 – Théorie

- (a) Justifier que la fonction  $J$  est différentiable et montrer que

$$\forall a \in \mathbb{R}^p, \quad \nabla J(a) = 2X^\top(Xa - y)$$

- (b) Montrer que  $J$  est une fonction convexe.

- (c) En déduire que l'ensemble des solutions de  $(\mathcal{P}_{\text{mm}})$  est l'ensemble des  $a \in \mathbb{R}^p$  tels que

$$X^\top Xa = X^\top y$$

- (d) On suppose que  $X$  est de rang  $n$ . Montrer que  $J$  est infinie à l'infini. En déduire que  $J$  admet au moins une solution.

- (e) Justifier que  $X^\top X$  est inversible. En déduire que l'unique solution de  $(\mathcal{P}_{\text{mm}})$  est le vecteur

$$a = (X^\top X)^{-1}(X^\top y)$$

1. Plusieurs choix sont possibles ; celui fait dans la méthode des moindres carrés correspond à l'hypothèse d'un bruit blanc gaussien additif.

Pour toute matrice  $M \in \mathcal{M}_{p,q}(\mathbb{R})$  de rang  $q$ , la matrice

$$M^\dagger = (M^\top M)^{-1} M^\top$$

est appelée *pseudo-inverse* de  $M$ .

On se place dans le cas de la régression linéaire en dimension 1. Prenons pour cela l'exemple loi d'OHM, qui stipule qu'il existe une relation linéaire entre l'intensité  $I$  du courant électrique qui traverse un conducteur et la tension  $U$  à ses bornes :

$$U = RI$$

Le rapport  $R$  (constant) entre la tension et l'intensité est appelé *résistance*. Afin d'estimer la valeur de la résistance d'un conducteur donné, on peut faire passer un courant d'une intensité connue  $I_0$  à travers le conducteur, puis mesurer la tension  $U_0$  associée ; enfin, faire le rapport et en déduire une valeur de résistance. Si l'on réitère l'expérience avec une autre valeur d'intensité  $I_1$  connue, on *devrait* trouver la même valeur de résistance.

En pratique, ce n'est pas le cas (et ce, même si  $I_0 = I_1$  !). De nombreux facteurs expliquent une telle différence : le voltmètre utilisé n'est pas suffisamment précis, l'affichage tronque la valeur de la tension, la loi d'OHM n'est qu'une loi théorique qui *approche* le comportement réel du conducteur... Ainsi, si on fait une série de  $n$  mesures de tension  $U_i$  associées à  $n$  valeurs d'intensité connues  $I_i$ , on a seulement

$$\forall i \in \llbracket 1; n \rrbracket, \quad U_i \approx RI_i$$

Estimer la valeur de la résistance revient donc à réaliser un ajustement linéaire sur les données  $\{(I_i, U_i)\}_{1 \leq i \leq n}$ , pour lequel on peut appliquer la méthode des moindres carrés. Le problème d'optimisation associé est le suivant

$$\min_{R \in \mathbb{R}} J(R) = \sum_{i=1}^n (RI_i - U_i)^2$$

### Exercice 2 – Régression linéaire

- (a) Choisir une valeur de  $R_{\text{théorique}} \in \mathbb{R}$ . Générer  $n = 10$  valeurs d'intensité  $I_i$ , puis générer  $n$  valeurs de tension  $U_i$ . Pour simuler l'imprécision des  $U_i$ , on ajoutera à chaque valeur théorique  $R_{\text{théorique}} I_i$  un bruit blanc gaussien de variance  $\sigma = ???$ .
- (b) Comment s'interprète la condition de rang maximal sur  $X$  dans le cadre de ce problème ?
- (c) Montrer que la valeur de résistance  $R$  optimale selon la méthode des moindres carrés est donnée par

$$R_{\text{optimal}} = \left( \sum_{i=1}^n I_i^2 \right)^{-1} \left( \sum_{i=1}^n I_i U_i \right)$$

- (d) Afficher sur le même graphique le nuage de points  $\{(I_i, U_i)_{1 \leq i \leq n}\}$  et les droites  $U = R_{\text{théorique}} I$  et  $U = R_{\text{optimal}} I$ .
- (e) Réaliser la même expérience en faisant varier le nombre de mesures  $n$  et le niveau de bruit  $\sigma$ . Qu'en concluez-vous ?

Si, au lieu d'estimer la valeur de résistance  $R$ , on choisit d'estimer la conductance  $G = 1/R$ , cela revient à considérer le modèle suivant

$$I = GU = \frac{U}{R}$$

On peut donc estimer  $G$  (et, de manière équivalente,  $R$ ) en *imposant* des valeurs  $U_i$  (connues) de tension aux bornes du conducteur et en *mesurant* l'intensité  $I_i$  qui traverse le conducteur ; ces valeurs vérifient

$$\forall i \in \llbracket 1 ; n \rrbracket, \quad I_i \approx G U_i = \frac{U_i}{R}$$

Ce sont cette fois les mesures  $I_i$  qui peuvent être entachées d'erreur ou d'imprécision. La méthode des moindres carrés appliquée à ce modèle revient à résoudre

$$\min_{G \in \mathbb{R}} \sum_{i=1}^n (G U_i - I_i)^2$$

Autrement dit, on inverse les rôles de  $U$  et de  $I$ .

### Exercice 3 – Estimation de la conductance

- (a) À partir des mêmes données que l'exercice précédent, mettre en œuvre la méthode des moindres carrés pour calculer la conductance optimale  $G_{\text{optimal}}$ .
- (b) Afficher sur le même graphique le nuage de points  $\{(I_i, U_i)_{1 \leq i \leq n}\}$  et les droites  $U = R_{\text{théorique}} I$ ,  $U = R_{\text{optimal}} I$  et  $U = I/G_{\text{optimal}}$ .
- (c) Qu'observez-vous ?

Lorsque l'on estime la résistance, la droite que l'on obtient minimise en moyenne la distance “verticale” aux points du nuage ; lorsque l'on estime la conductance, la droite minimise en moyenne la distance “horizontale” aux points du nuage. Il est naturel de chercher à trouver la droite qui minimise la distance euclidienne aux points du nuage. Celle-ci est définie pour la droite  $\mathcal{D}$  d'équation  $RI - U = 0$  par

$$\text{dist}(I_i, U_i; \mathcal{D}) = \frac{|RI_i - U_i|}{R + 1} = \frac{|I_i - GU_i|}{G + 1}$$

Les problèmes d'optimisation s'écrivent donc

$$\min_{R \in \mathbb{R}} \sum_{i=1}^n \frac{(RI_i - U_i)^2}{(R + 1)^2} \quad \text{et} \quad \min_{G \in \mathbb{R}} \sum_{i=1}^n \frac{(I_i - GU_i)^2}{(G + 1)^2}$$

Du point de vue de la modélisation, cela revient à considérer que les valeurs d'intensité **et** de tension ne sont pas fiables.

### Exercice 4 – Minimisation de la distance des points à la droite

- (a) Justifier que, si l'on part des mêmes données, estimer la résistance ou la conductance conduira au même résultat. Autrement dit,  $R_{\text{optimal}} = 1/G_{\text{optimal}}$ .
- (b) Montrer que

$$R_{\text{optimal}} = \left( \sum_{i=1}^n I_i (I_i + U_i) \right)^{-1} \left( \sum_{i=1}^n U_i (I_i + U_i) \right)$$

On termine ce premier TP avec un exemple de régression polynomiale. On suppose cette fois que l'on dispose de  $n$  couples de données  $(x_i, y_i) \in \mathbb{R}^2$  satisfaisant

$$\forall i \in \llbracket 1 ; n \rrbracket, \quad y_i \approx P(x_i)$$

avec  $P$  un polynôme réel de degré au plus  $p$ . Tout tel polynôme est défini de manière unique par un vecteur  $a = (a_i)_{0 \leq k \leq p}$  en écrivant

$$P(X) = \sum_{k=0}^p a_k X^k$$

L'ajustement polynomial des données par méthode des moindres carrés consiste donc à résoudre le problème d'optimisation

$$\min_{a \in \mathbb{R}^{p+1}} \sum_{i=1}^n \left( \sum_{k=0}^p a_k x_i^k - y_i \right)^2$$

### Exercice 5 – Théorie

- (a) Montrer que le problème ci-dessus peut se réécrire

$$\min_{a \in \mathbb{R}^{p+1}} \|X a - y\|_2^2$$

avec  $X = (x_i^k)_{\substack{1 \leq i \leq n \\ 0 \leq k \leq p}}$  et  $y = (y_i)_{1 \leq i \leq n}$ .

- (b) En déduire que les solutions du problème sont les vecteurs  $a \in \mathbb{R}^{p+1}$  solutions du système linéaire

$$X^\top X a = y$$

Sous quelles conditions ce système admet-il une solution ?

La matrice  $X$  définie dans l'exercice précédent est connue sous le nom de matrice de VANDERMONDE.

### Exercice 6 – Régression polynomiale

- (a) Choisir un vecteur  $a \in \mathbb{R}^6$ . Générer  $n = 10$  valeurs  $x_i$ , puis générer  $n$  valeurs  $y_i \approx P(x_i)$  avec  $P$  le polynôme associé. Pour simuler l'imprécision des  $y_i$ , on ajoutera à chaque valeur théorique  $P(x_i)$  un bruit blanc gaussien de variance  $\sigma = ???$ .
- (b) Réaliser l'ajustement polynomial pour des degrés entre  $p = 0$  et  $p = 6$ . Afficher sur le même graphique le nuage de points  $\{(x_i, y_i)_{1 \leq i \leq n}\}$ , le polynôme  $P$  théorique et les 7 ajustements polynomiaux.